

Modelagem Multivariada de Heteroscedasticidade para Estimativa de Risco Dinâmico em Otimização de Portfólio

Introdução

O problema de otimização de portfólio é um desafio fundamental na teoria financeira que envolve a alocação eficiente de recursos em diferentes ativos. O objetivo é encontrar a combinação ideal de investimentos que maximize o retorno esperado para um determinado nível de risco, levando em conta restrições de investimento como limitações de alocação e liquidez. Central ao problema é a definição de uma medida de risco, responsável por quantificar o potencial de perda financeira associado à um portfólio

A medida de risco tradicional em otimização de portfólio é variância, seguindo o método de Média-Variância (MV) proposto por Markowitz [1]. Apesar de conveniente devido à sua simplicidade esta medida não possui muitas propriedades desejáveis [2], tornando comum o uso de medidas mais elaboradas [3]. Um dos problemas da variância, compartilhado por muitas medidas mais sofisticadas, é a suposição que risco é estático no tempo, enquanto mercados financeiros são dinâmicos e sujeitos à constante variação temporal [4]. Métricas de risco que tentam capturar a natureza dinâmica de uma carteira de investimentos são apropriadamente denominadas “medidas de risco dinâmicas”.

A incorporação de medidas de risco dinâmicas em otimização de portfólio pode ser útil para a geração de representações mais precisas de risco instantâneo [5] e para a construção de portfólios dinâmicos, cuja distribuição de investimentos evolui ao longo do tempo por meio de políticas de rebalanceamento [6, 7]. Como várias medidas de risco são calculadas a partir da matriz de covariância das séries temporais de preços ou retornos dos ativos de uma carteira, a modelagem temporal da matriz de covariância é uma forma de gerar métricas de risco dinâmicas que é bem estudada na literatura [5].

A modelagem temporal da matriz de covariância de um conjunto de séries temporais é essencialmente um problema de modelagem de heteroscedasticidade multivariada. Dentre os modelos tradicionais com esta finalidade, os propostos por Engle [8] geram medidas de risco dinâmicas mais representativas que suas contrapartidas estáticas [6, 7, 9]. Há uma série de problemas no uso prático destes modelos que decorrem de sua natureza paramétrica [10], sugerindo o uso de modelos de *machine learning* (ML) como uma alternativa mais flexível.

A aplicação de algoritmos de ML para modelagem temporal de matrizes de covariância atinge resultados melhores que abordagens tradicionais em alguns trabalhos [11, 12]. Aprendizado profundo, em particular, apresenta resultados promissores em estudos recentes [?, 13].

O objetivo do projeto proposto é investigar soluções de otimização de portfólio a partir de uma medida de risco dinâmica obtida por meio de modelagem multivariada de heteroscedasticidade de preços e retornos de ativos financeiros. Serão explorados modelos paramétricos, não paramétricos e híbridos com uma ênfase em aprendizado profundo. (incluir isso?) Como objetivo secundário será escrito um

sistema para avaliação prática do método de otimização de portfólio desenvolvido.

Referencial Teórico

Um dos primeiros modelos para heteroscedasticidade de séries temporais foi proposto por Bollerslev (1986) como uma continuação do trabalho de Engle (1982) [14]. O modelo de Bollerslev, cunhado *Generalized Autoregressive Conditional Heteroscedasticity* (GARCH), é amplamente usado em econometria financeira desde sua criação. Tentativas iniciais de desenvolver um modelo responsável pela representação de covariância condicional entre múltiplas séries partiram de uma generalização do GARCH para o contexto multivariado, resultando na classe denominada por Bauwens et. al [8] como *Multivariate GARCH* (MGARCH).

É observado por múltiplos autores [8, 10] que o uso da maioria dos modelos MGARCH possui uma série de dificuldades práticas quanto à especificação de estrutura, identificação de modelo, ajuste de parâmetros e complexidade computacional. Uma notável exceção é o *Dynamic Conditional Correlation* (DCC) [15], desenvolvido com o propósito de contornar essas limitações. Fiszeder et. al [11] argumenta que abordagens de aprendizado de máquina não sofrem dos mesmo problemas devido ao fato de envolverem modelos menos paramétricos. Christensen et. al [16] faz um estudo comparativo da aplicação de diversos algoritmos de ML tradicionais para previsão de variância condicional univariada, demonstrando superioridade em relação à uma seleção de métodos econométricos. Xiong et. al [17] realiza um estudo semelhante com redes neurais *Long Short Term Memory* (LSTM), concluindo expressiva melhora de desempenho da LSTM em relação a um *benchmark* GARCH. Fechar falando sobre ML e DL para multivariada?

Chan et. al (1999) [5] apresenta um dos primeiros artigos influentes a diretamente investigar o impacto do emprego de variância dinâmica, obtida a partir de modelagem de covariância, no método de otimização MV. É observado pelos autores que a variância dinâmica gera resultados melhores como métrica de risco instantânea do que variância histórica. Modelos MGARCH são utilizados para construção de portfólios com políticas de rebalanceamento em [7] e [9], produzindo resultados melhores do que métodos correspondentes baseados em risco histórico. Com o mesmo objetivo Metin (2022) [6] emprega o modelo DCC, motivado pela possibilidade de inclusão de um maior número de ativos no portfólio dinâmico, obtendo resultados positivos e mais flexíveis quando comparado ao uso de outros modelos MGARCH. Há uma série de trabalhos com objetivo semelhante que utilizam de modelos de ML. Redes neurais artificiais são usadas em [12], produzindo resultados piores que modelos econométricos elaborados, e regressão por vetor suporte é usado em [11], atingindo acurácia e retornos melhores que um *benchmark* DCC. Em [13] a união de modelos LSTM e *Convolutional Neural Networks* (CNNs) é explorada a fim de aprimorar a extração de características das séries modeladas, gerando resultados superiores à otimização baseada em variância.

Boulet (2021) [18] afirma que apesar de promissoras, abordagens de aprendizado profundo para previsão de matrizes de covariância foram pouco exploradas. Neste mesmo trabalho é apresentado uma arquitetura híbrida que une os modelos

GARCH e LSTM, superando abordagens baseadas em MGARCH.

Metodologia

p1: Detalhar o que será feito p2: Descrever sistema desenvolvido para testar método p3: Descrever dados utilizados p4: Descrever métodos de avaliação

Cronograma

Conforme estabelecido pela estrutura curricular do PPGCC será cursada a disciplina Projeto e Análise de Algoritmos do Núcleo Comum. Das disciplinas das linhas de pesquisa de Inteligência Artificial e Otimização há interesse do candidato em cursar Fundamentos de Estatística para Ciência dos Dados B, Aprendizado Profundo, Aprendizado de Máquina, Programação Não Linear e Programação Estocástica. Das demais destaca-se a matéria Finanças Quantitativas e Gerenciamento de Risco. As matérias serão cursadas de acordo com o planejamento conjunto do aluno e orientador e oferta.

As atividades pertinentes à pesquisa do candidato serão distribuídas entre os quatro semestres da seguinte maneira:

1. Revisão de literatura e experimentos iniciais com base de dados M6.
2. Início de desenvolvimento de sistema de otimização e elaboração do método proposto.
3. Finalização do sistema de otimização. Experimentos com o método proposto. Ajustes no método.
4. Avaliação de experimentos finais e redação de dissertação.

Referências

- [1] H. Markowitz, "Portfolio selection," *The Journal of Finance*, vol. 7, no. 1, pp. 77–91, 1952.
- [2] S. Rachev, S. Ortobelli, S. Stoyanov, F. J. Fabozzi, and A. Biglova, "Desirable properties of an ideal risk measure in portfolio theory," *International Journal of Theoretical and Applied Finance*, vol. 11, no. 01, pp. 19–54, 2008.
- [3] P. S. N. Gambrah and T. A. Pirvu, "Risk measures and portfolio optimization," *Journal of Risk and Financial Management*, vol. 7, no. 3, pp. 113–129, 2014.
- [4] P. F. Procacci and T. Aste, "Portfolio optimization with sparse multivariate modeling," *Journal of Asset Management*, vol. 23, no. 6, pp. 445–465, 2022.
- [5] L. K. Chan, J. Karceski, and J. Lakonishok, "On portfolio optimization: Forecasting covariances and choosing the risk model," *The review of Financial studies*, vol. 12, no. 5, pp. 937–974, 1999.

- [6] M. Ilbasmis, “Asset allocation with dynamic conditional correlations (dcc) model,” *Pamukkale University Journal of Social Sciences*, pp. 150–175, 2022.
- [7] D. M. Holten and L. H. Sendstad, “Evaluation dynamic covariance matrix forecasting and portfolio optimization,” Master’s thesis, 2012.
- [8] L. Bauwens, S. Laurent, and J. V. K. Rombouts, “Multivariate garch models: a survey,” *Journal of Applied Econometrics*, vol. 21, no. 1, pp. 79–109, 2006.
- [9] J. E. Weirum and C. E. Jensen, “Creating optimal portfolios of stocks with time-varying risk,” Master’s thesis, 2013.
- [10] P. A. Morettin, *Econometria financeira: um curso em séries temporais financeiras*. Editora Blucher, 2017.
- [11] P. Fiszeder and W. Orzeszko, “Covariance matrix forecasting using support vector regression,” *Applied intelligence*, vol. 51, no. 10, pp. 7029–7042, 2021.
- [12] A. Bucci, “Cholesky–ann models for predicting multivariate realized volatility,” *Journal of Forecasting*, vol. 39, no. 6, pp. 865–876, 2020.
- [13] M. Wysocki, P. Sakowski, *et al.*, “Investment portfolio optimization based on modern portfolio theory and deep learning models,” tech. rep., 2022.
- [14] T. Bollerslev, “Generalized autoregressive conditional heteroskedasticity,” *Journal of econometrics*, vol. 31, no. 3, pp. 307–327, 1986.
- [15] R. Engle, “Dynamic conditional correlation,” *Journal of Business & Economic Statistics*, vol. 20, no. 3, pp. 339–350, 2002.
- [16] K. Christensen, M. Siggaard, and B. Veliyev, “A machine learning approach to volatility forecasting,” *Available at SSRN*, 2021.
- [17] R. Xiong, E. P. Nichols, and Y. Shen, “Deep learning stock volatility with google domestic trends,” 2016.
- [18] L. Boulet, “Forecasting high-dimensional covariance matrices of asset returns with hybrid garch-lstms,” 2021.